

Processi Pitman-Yor Dipendenti: Modello, Dipendenza e Inferenza

Analisi Bayesiana Non Parametrica

13 gennaio 2026

Sommario

In questo lavoro analizziamo una classe di processi Pitman-Yor dipendenti (DPY) basati sulla costruzione *Dependent Stick-Breaking*. Ci concentriamo sulla specificazione simmetrica (H1) con struttura gerarchica ANOVA sugli atomi, proponendo un algoritmo di campionamento basato su troncamento finito. Attraverso uno studio di simulazione su quattro scenari, valutiamo la capacità del modello di recuperare strutture di densità eterogenee tra gruppi, analizzando in particolare la dipendenza indotta sui pesi (“Shared Complexity”). Dicitiamo inoltre le differenze principali tra Dirichlet process e Pitman-Yor process.

1 Introduzione

Bassetti et al. (2014) propongono una nuova classe di processi Pitman-Yor dipendenti (DPY). Tale processo è stato introdotto originariamente da Pitman and Yor (1997) come generalizzazione del Processo di Dirichlet (Ferguson, 1973). La costruzione *stick-breaking* ci permette di apprezzare tale generalizzazione:

$$G \sim \text{PY}(\alpha, \theta, G_0) \quad (1)$$

con la rappresentazione stick-breaking definita da:

$$W_k = V_k \prod_{j < k} (1 - V_j) \quad (2)$$

$$V_k \stackrel{\text{ind}}{\sim} \text{Beta}(1 - \alpha, \theta + \alpha k), \quad k \geq 1 \quad (3)$$

$$G = \sum_{k=1}^{\infty} W_k \delta_{\theta_k^*}, \quad \theta_k^* \stackrel{\text{iid}}{\sim} G_0 \quad (4)$$

È facile notare che quando $\alpha = 0$ recuperiamo il processo di Dirichlet. Entrambi i processi sono ampiamente utilizzati come *prior* per modelli di mistura in un contesto Bayesiano non parametrico.

Tuttavia, un limite di questi processi standard è l’assunzione di indipendenza o scambiabilità totale tra le unità. In contesti come l’analisi di dati panel o misure ripetute, è fondamentale modellare densità diverse per i vari gruppi (eterogeneità) mantenendo però una struttura di dipendenza che permetta il *borrowing of strength*. Questo porta alla costruzione di vettori di distribuzioni casuali dipendenti (MacEachern, 1999, 2001).

2 Alcune differenze tra i Processi Dirichlet e Pitman-Yor

La Figura 1 evidenzia un vantaggio fondamentale del Pitman-Yor rispetto al Dirichlet Process standard:

Crescita del Numero di Cluster:

Il comportamento asintotico dei due processi è radicalmente diverso:

$$\text{DP: } \mathbb{E}[K_n] \approx \theta \log(n) \quad (\text{crescita logaritmica}) \quad (5)$$

$$\text{PY: } \mathbb{E}[K_n] \approx \frac{\Gamma(\theta + \alpha)}{\Gamma(\theta + 1)} n^\alpha \propto n^\alpha \quad (\text{crescita power-law}) \quad (6)$$

Dove K_n è il numero di cluster dopo n osservazioni. Con $\alpha \in (0, 1)$, il PY produce un numero di cluster che cresce molto più rapidamente del DP, permettendo di catturare la ricchezza della struttura nei dati, vedi Teh (2006). Inoltre possiamo analizzare la distribuzione dei pesi.

DP: La distribuzione $\text{GEM}(\theta)$ produce pesi che decadono geometricamente, risultando in una rank-size distribution con decadimento esponenziale (rapido). Questo è visibile nel grafico log-log come una curva ripida.

PY: La distribuzione $\text{PY}(\alpha, \theta)$ produce una vera power law (relazione lineare nel grafico log-log). I pesi decadono seguendo $W_k \propto k^{-(1+\alpha)}$, creando code molto più pesanti. Anche i pesi del PY seguono la distribuzione $\text{GEM}(\alpha, \theta)$.




Figura 1: Crescita numero di cluster

3 Dependent Stick Breaking

3.1 Definizione

Definiamo il vettore di misure random dipendenti come (Bassetti et al., 2014):

$$G_i(\cdot) = \sum_{k \geq 1} W_{ik} \delta_{\tilde{\psi}_{ik}}(\cdot) \quad i = 1, \dots, r \quad (7)$$

Componenti:

• **Pesi:** $\mathbf{W}_k = (W_{1k}, \dots, W_{rk})$

• **Atomi:** $\tilde{\psi}_k = (\tilde{\psi}_{1k}, \dots, \tilde{\psi}_{rk})$

Assunzioni:

• **Indipendenza:** $(\tilde{\psi}_k)_k \perp (\mathbf{W}_k)_k$

• **Atomi i.i.d.:** $(\tilde{\psi}_k)_k \stackrel{\text{i.i.d.}}{\sim} G_0$ in Ψ^r

La costruzione **Stick-breaking Dipendente** è data da:

$$W_{ik} = S_{ik} \prod_{j < k} (1 - S_{ij}), \quad i = 1, \dots, r$$

dove $\mathbf{S}_k = (S_{1k}, \dots, S_{rk})$ sono vettori indipendenti in $[0, 1]^r$ con la condizione $\sum_{k \geq 1} W_{ik} = 1$ quasi certamente (GEM distribution).

Modello di Mistura per Misure Ripetute

Consideriamo la densità condizionata:

$$f_i(y) = \sum_{k \geq 1} W_{ik} \mathcal{K}(y \mid \tilde{\psi}_{ik}) \quad (8)$$

$$\mathcal{K}(y \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - \mu)^2 \right\} \quad (9)$$

Il DPY prior su $(\mathbf{W}, \tilde{\psi})$ induce una struttura di clustering dipendente tra i gruppi.

4 Beta-product Dependent Pitman-Yor (H1)

In letteratura vengono proposte diverse costruzioni per la dipendenza. In questa analisi ci concentreremo esclusivamente sulla costruzione Simmetrica (H1) (Bassetti et al., 2014), in quanto garantisce a priori lo stesso numero atteso di cluster per entrambe le unità, rendendola ideale per il confronto tra gruppi bilanciati.

Costruzione (H1) - Simmetrica: La dipendenza è indotta attraverso un fattore latente comune V_{0k} :

$$(S_{1k}, S_{2k}) = (V_{0k}V_{1k}, V_{0k}V_{2k}) \quad (10)$$

con V_{0k}, V_{1k}, V_{2k} indipendenti distribuiti come:

$$V_{0k} \sim \text{Beta}(1 - \alpha, \theta_1) \quad (11)$$

$$V_{1k}, V_{2k} \sim \text{Beta}(1 - \alpha + \theta_1, \theta_2 + \alpha k) \quad (12)$$

con $\theta_1 > 0, \theta_2 > 0$ e $\alpha \in [0, 1)$.

Marginali: $G_1, G_2 \sim \text{PY}(\alpha, \theta_1 + \theta_2, G_0)$.

4.1 Casi Limite e Flessibilità

Un vantaggio cruciale della costruzione H1 è la sua capacità di coprire l'intero spettro di dipendenza attraverso la calibrazione degli iperparametri θ_1 e θ_2 :

- **Indipendenza Asintotica:** Quando $\theta_1 \rightarrow 0$, la varianza del fattore comune V_{0k} tende a zero, rendendo i vettori S_{1k} e S_{2k} asintoticamente indipendenti. In questo regime, il modello si comporta come due processi Pitman-Yor separati.
- **Dipendenza Forte:** Valori elevati di θ_1 aumentano la correlazione tra gli stick, forzando i due gruppi a condividere pesi simili.

5 Struttura Gerarchica degli Atomi (ANOVA)

Per consentire diversi gradi di condivisione dell'informazione (*pooling*) anche sulla posizione e forma dei cluster, adottiamo una struttura gerarchica di tipo *ANOVA-like* per i parametri del kernel gaussiano $\psi = (\mu, \sigma^2)$, come proposto in De Iorio et al. (2004) e applicato in Bassetti et al. (2014).

Ogni atomo della miscela $\tilde{\psi}_{ik}$ è definito come combinazione di una componente comune e di una specifica per il gruppo:

$$\tilde{\psi}_{ik} = (\tilde{\mu}_{0k} + \tilde{\mu}_{ik}, \tilde{\sigma}_{0k}^2 \tilde{\sigma}_{ik}^2) \quad (13)$$

dove:

- $(\tilde{\mu}_{0k}, \tilde{\sigma}_{0k}^2)$ rappresentano la **media e varianza comuni** (baseline) della k -esima componente.
- $(\tilde{\mu}_{ik}, \tilde{\sigma}_{ik}^2)$ rappresentano gli **scostamenti specifici** (offset additivi e moltiplicativi) per il gruppo i -esimo.

La specificazione della misura base G_0 è completata assegnando le seguenti distribuzioni a priori indipendenti [Eq. 19 Bassetti et al. (2014)]:

$$\text{Specifici: } (\tilde{\mu}_{ik}, \tilde{\sigma}_{ik}^2) \sim \mathcal{N}(0, s_i^{-2}) \times \mathcal{IG}(\lambda/2, \lambda/2) \quad \text{per } i = 1, 2 \quad (14)$$

$$\text{Comuni: } (\tilde{\mu}_{0k}, \tilde{\sigma}_{0k}^2) \sim \mathcal{N}(0, s_0^{-2}) \times \mathcal{IG}(\epsilon/2, \epsilon/2) \quad (15)$$

Questa struttura implica che, a priori, i cluster dei diversi gruppi siano variazioni attorno a una "forma base" comune.

6 Interpretazione della Dipendenza nel DPYP

Il modello DPYP con struttura ANOVA induce due livelli distinti di dipendenza tra i gruppi, permettendo una grande flessibilità interpretativa.

6.1 Livello 1: Shared Complexity (Pesi)

Nel framework *Dependent Stick-Breaking*, V_{0k} agisce come un "governatore globale" dell'importanza della k -esima componente. Se il modello rileva che per spiegare i dati del Gruppo 1 è necessaria una componente massiccia (cluster dominante), la struttura di dipendenza incoraggia il Gruppo 2 ad allocare anch'esso una componente dominante nello stesso indice k . Questo porta alla forte correlazione dei pesi che verrà osservata empiricamente negli scatter plot dei risultati.

6.2 Livello 2: Shared Location (Atomi ANOVA)

A differenza di un modello a atomi indipendenti, la struttura ANOVA introduce una correlazione anche nella localizzazione fisica dei cluster:

$$\text{Cov}(\mu_{1k}, \mu_{2k}) = \text{Var}(\tilde{\mu}_{0k}) = s_0^{-2} \quad (16)$$

Il grado di allineamento tra i cluster dei due gruppi è regolato dalla varianza della componente specifica s_i^{-2} :

- **Prior Diffusa (s_i^2 grande):** I gruppi condividono la complessità (pesi) ma possono collocare i cluster in posizioni molto diverse ("Shifted Structure").
- **Prior Informativa (s_i^2 piccolo):** I gruppi sono costretti a condividere sia i pesi che le posizioni, risultando in una struttura di mistura quasi identica ("Aligned Structure").

7 Approssimazione Computazionale

Il modello teorico ha dimensione infinita. In questa analisi preferiamo un approccio per Troncamento Finito (Ishwaran and James, 2001) rispetto allo Slice Sampling. Fissiamo un numero massimo di componenti K_{max} , assumendo trascurabile il contributo delle code ($k > K_{max}$).

L'approssimazione troncata implica:

$$G_i(\cdot) \approx \sum_{k=1}^{K_{max}} W_{ik} \delta_{\tilde{\psi}_{ik}}(\cdot)$$

con $V_{K_{max}} = 1$ per chiudere lo stick. L'algoritmo Gibbs Sampler procede aggiornando iterativamente:

1. **Allocazioni z_{it} :** condizionatamente ai parametri totali del cluster.
2. **Atomi ANOVA:** aggiornando separatamente le componenti comuni (μ_0, σ_0) e specifiche (μ_i, σ_i) tramite passi coniugati Normal-InverseGamma.
3. **Stick V_k :** tramite step Metropolis-Hastings nello spazio logit.
4. **Iperparametri:** $\theta_1, \theta_2, \alpha$ tramite Random Walk Metropolis.

8 Densità Predittiva

Per valutare il fit del modello, stimiamo la densità predittiva a posteriori tramite media delle densità condizionate (Bassetti et al., 2014):

$$\hat{f}_i(y) \approx \frac{1}{M} \sum_{l=1}^M \sum_{k=1}^{K_{max}} W_{ik}^{(l)} \mathcal{K}(y | \tilde{\psi}_{ik}^{(l)})$$

Questo stimatore produce le curve di densità “smooth” presentate nei risultati grafici (Posterior Mean Density), incorporando l'incertezza su parametri e pesi.

9 Studio di Simulazione

Seguendo la sezione 6.1 del paper abbiamo riprodotto tutti e quattro i mix presentati. I risultati si possono vedere nella Figura 2. I risultati sono ottimi, la discrepanza tra i risultati ottenuti in questa riproduzione e la simulazione del paper è riconducibile alla decisione di utilizzare il trocamento anziché lo slice sampler all'interno della computazione.






Figura 2: Posterior Densities

Per enfatizzare la dipendenza tra i pesi e gli atomi abbiamo costruito un grafico di correlazione. La Figura 3 mostra la distribuzione congiunta dei pesi (W_{1k}, W_{2k}) per i principali cluster identificati nei diversi scenari di simulazione. Dall'analisi grafica emergono due risultati fondamentali: **Allineamento Diagonale (Shared Complexity)**: Si osserva una marcata concentrazione dei punti lungo la bisettrice (45°). Questo conferma che il modello DPYP cattura efficacemente la dipendenza a priori introdotta dalla costruzione *Dependent Stick-Breaking*: i cluster che hanno un peso rilevante nel Gruppo 1 tendono ad avere un peso comparabile nel Gruppo 2. Questo comportamento indica un corretto "borrowing of strength" sui pesi, essenziale per stabilizzare la stima in presenza di dati eterogenei ma correlati. **Identificazione della Struttura Latente**: I pannelli mostrano chiaramente la capacità del modello di separare i diversi cluster: Negli scenari **Mix1 e Mix2** (pannello superiore), i cluster principali sono ben definiti e bilanciati, riflettendo la struttura semplice dei dati generati. Negli scenari più complessi **Mix3 e Mix4** (pannello inferiore), il modello riesce a isolare correttamente anche componenti con medie vicine o pesi sbilanciati.

In particolare, la presenza di cluster con parametri μ e σ^2 quasi identici tra i due gruppi (come evidenziato dalle etichette nei box) dimostra l'efficacia della struttura gerarchica ANOVA: la componente comune (μ_{0k}) agisce come un forte attrattore, allineando non solo l'importanza (peso) ma anche la posizione fisica delle componenti nei due gruppi.



(a) Scenari 1 e 2: Mix1 e Mix2



(b) Scenari 3 e 4: Mix3 e Mix4

Figura 3: Analisi delle correlazioni

10 Applicazione con dati reali

"Questa classe di modelli si rivela particolarmente efficace nell'analisi di strutture di dati non unimodali. Le possibili applicazioni spaziano dalla finanza computazionale, come proposto originariamente in Bassetti et al. (2014), alla biologia, ad esempio per l'identificazione di cluster di Copy Number Aberrations (CNAs) caratterizzati da comportamenti di tipo power-law. Per questa analisi empirica, si è scelto di utilizzare il dataset pubblico rilasciato da IBM relativo all'ammontare delle transazioni con carte di credito. Tali dati mostrano una natura fortemente multimodale, tipica del contesto statunitense: sebbene la maggior parte delle transazioni si concentri su valori modesti ($< 100\$$), una quota sostanziale si colloca nella fascia $100\$ - 200\$$. Inoltre, il dataset include valori negativi, corrispondenti ai rimborsi, e transazioni di importo elevato ("code pesanti"), permettendo di testare la capacità del processo DPYP di catturare anche cluster di piccole dimensioni. Nello specifico, verranno prese in considerazione le transazioni avvenute nel biennio 2008-2009. Tale struttura temporale si presta ottimamente all'applicazione del modello proposto: è logico, infatti, attendersi una forte correlazione di fondo nelle abitudini di spesa tra due anni consecutivi. Tuttavia, data la GFC del 2008, è altrettanto ragionevole aspettarsi che i cluster latenti presentino caratteristiche distributive lievemente divergenti, mettendo alla prova la flessibilità della struttura di dipendenza del modello.




Figura 4: Densità a posteriori

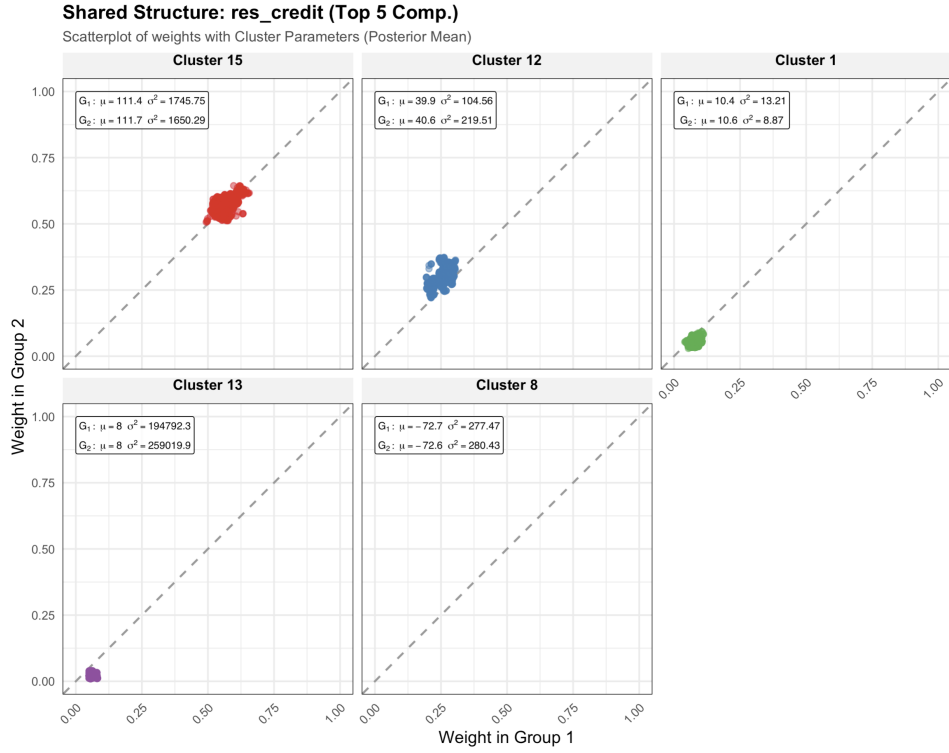


Figura 5: Correlation Plot




Figura 6: Trace Plots

Il modello cattura bene le diversi componenti delle abitudini di spesa. Anche i rimborsi sono catturati ottimamente dal modello. Da una prima analisi ci aspettavamo un comportamento migliore anche per le transazioni elevate. Controllando meglio il dataset però ci accorgiamo che solo 5 transazioni su oltre 1200 supera i 400\$.

11 Conclusioni

In questo lavoro abbiamo analizzato e implementato una classe flessibile di modelli Bayesiani non parametrici per l'analisi di dati in gruppi dipendenti, basata sul Processo di Pitman-Yor Dipendente (DPYP) con costruzione *Dependent Stick-Breaking*. L'obiettivo principale era introdurre una struttura di dipendenza esplicita sia sui pesi che sulla localizzazione dei cluster.

Sintesi dei Risultati

L'analisi empirica, condotta sia su dataset sintetici che su dati reali relativi alle transazioni con carte di credito, ha evidenziato alcuni risultati fondamentali:

- **Gestione delle Code Pesanti (Heavy Tails):** Il confronto diretto tra la specificazione Dirichlet ($\alpha \rightarrow 0$) e Pitman-Yor ($\alpha > 0$) ha dimostrato la superiorità di quest'ultimo nel catturare strutture a "coda lunga". Mentre il Processo di Dirichlet tende a sottostimare il numero di componenti latenti accorpono i cluster minori, il DPYP preserva l'informazione contenuta nei cluster di piccola dimensione (es. transazioni anomale o di importo elevato), risultando cruciale in contesti finanziari e di risk management.
- **Efficacia della Struttura ANOVA:** L'introduzione di una gerarchia di tipo ANOVA sugli atomi ($\tilde{\psi}_{ik} = \mu_{0k} + \mu_{ik}$) ha permesso di separare la struttura latente comune dalle idiosincrasie di gruppo. Gli scatter plot dei pesi posteriori hanno confermato che, sotto prior informative per la varianza specifica (s_i^2), il modello induce un forte *borrowing of strength*, allineando fisicamente i cluster tra i gruppi e permettendo un confronto diretto tra le densità.

In conclusione, il modello DPYP con struttura ANOVA si conferma uno strumento robusto e interpretabile per l'analisi di eterogeneità non osservata, offrendo un bilanciamento ottimale tra complessità teorica e capacità di adattamento ai dati.

Riferimenti bibliografici

- Federico Bassetti, Roberto Casarin, and Fabrizio Leisen. Beta-product dependent Pitman–Yor processes for Bayesian inference. *Journal of Econometrics*, 180(1):49–72, 2014. doi: 10.1016/j.jeconom.2014.01.007.
- Maria De Iorio, Peter Müller, Gary L. Rosner, and Steven N. MacEachern. An ANOVA model for dependent random measures. *Journal of the American Statistical Association*, 99(465):205–215, 2004. doi: 10.1198/016214504000000205.
- Thomas S. Ferguson. A Bayesian analysis of some nonparametric problems. *The Annals of Statistics*, 1(2):209–230, 1973.
- Hemant Ishwaran and Lancelot F. James. Gibbs sampling methods for stick-breaking priors. *Journal of the American Statistical Association*, 96(453):161–173, 2001. doi: 10.1198/016214501750332758.
- Steven N. MacEachern. Dependent nonparametric processes. In *Proceedings of the Bayesian Statistical Science Section*, pages 50–55, Alexandria, VA, 1999. American Statistical Association.
- Steven N. MacEachern. Decision theoretic aspects of dependent nonparametric processes. In T. Fomby and R. C. Hill, editors, *Bayesian Methods with Applications to Science, Policy and Official Statistics*, pages 551–560. International Society for Bayesian Analysis, 2001.
- Jim Pitman and Marc Yor. The two-parameter Poisson–Dirichlet distribution derived from a stable subordinator. *The Annals of Probability*, 25(2):855–900, 1997. doi: 10.1214/aop/1024404422.
- Yee Whye Teh. A hierarchical Bayesian language model based on Pitman-Yor processes. In Nicoletta Calzolari, Claire Cardie, and Pierre Isabelle, editors, *Proceedings of the 21st International Conference on Computational Linguistics and 44th Annual Meeting of the Association for Computational Linguistics*, pages 985–992, Sydney, Australia, July 2006. Association for Computational Linguistics. doi: 10.3115/1220175.1220299. URL <https://aclanthology.org/P06-1124/>.